# Construção de Compiladores - INE5426

Relatório - AL 1
Construção de Analisador Léxico

Universidade Federal de Santa Catarina

Eduardo Gutterres [17200439]
Felipe de Campos Santos [17200441]
Ricardo Giuliani [17203922]

# 1. Identificação dos tokens

## Operadores Aritméticos

- PLUS → símbolo de adição
- MINUS → símbolo de subtração
- TIMES → símbolo de multiplicação (asterisco)
- DIVIDE → símbolo de divisão (barra)
- MOD → símbolo de resto de divisão (porcento)
- ASSIGN → símbolo de igual

## Operadores Relacionais

- EQUAL → dois símbolos de igual
- DIFFERENT → exclamação seguida de símbolo de igual
- LT (LESS THAN) → símbolo de menor
- LE (LESS THAN OR EQUAL) → símbolo de menor seguido de símbolo de igual
- GT (GREATER THAN) → símbolo de maior
- GE (GREATER THAN OR EQUAL) → símbolo de maior seguido de símbolo de igual

## Outros Operadores

- COMMA → vírgula
- SEMICOLON → ponto e vírgula
- RPARENTHESES → parênteses direito
- LPARENTHESES → parênteses esquerdo
- LBRACKET → colchete esquerdo
- RBRACKET → colchete direito
- LBRACE → chave esquerda
- RBRACE → chave direita
- DOT → ponto

## Constantes

- FLOATCONSTANT → número com decimal
- INTCONSTANT → número (decimal, hexadecimal, octal ou binario)
- STRINGCONSTANT → constante entre aspas

## Tokens ignorados

- LINEBREAK → quebra de linha
- COMMENT → qualquer coisa entre /* e */ ou após // na mesma linha
- TAB → espaço tabulado

# 2. Definições regulares dos tokens

## Operadores Aritméticos

- PLUS → +
- MINUS → -
- TIMES → *
- DIVIDE → /
- MOD → %
- ASSIGN → =

## Operadores Relacionais

- EQUAL → ==
- DIFFERENT → !=
- LT (LESS THAN) → <
- LE (LESS THAN OR EQUAL) → <=
- GT (GREATER THAN) → >
- GE (GREATER THAN OR EQUAL) → >=

## Outros Operadores

- COMMA → ,
- SEMICOLON → ;
- RPARENTHESES → )
- LPARENTHESES → (
- LBRACKET → [
- RBRACKET → ]
- LBRACE → {
- RBRACE → }
- DOT → .

## Constantes

- FLOATCONSTANT → (NUMERO).(NUMERO)+
- INTCONSTANT → (NUMERO)+ | (0|1)+ [b|B] | (NUMERO | A-F)+ [h|H] | (0-7)+ [o|O]
- STRINGCONSTANT → “ (NUMERO | LETRA) (^ \n | \r | “ ) “

## Tokens ignorados

- LINEBREAK → \n+
- COMMENT → // (LETRA | NUMERO)+ | /* (LETRA | NUMERO)+ */
- TAB → \t+

- LETRA → (a | b | c | d | … | z | A | B | C | … | Z)
- NUMERO → (0 | 1 | 2 | … | 0)

# 3. Diagramas de transição dos tokens

Abaixo, 3 diagramas de transição como exemplo:

**INTCONSTANT**

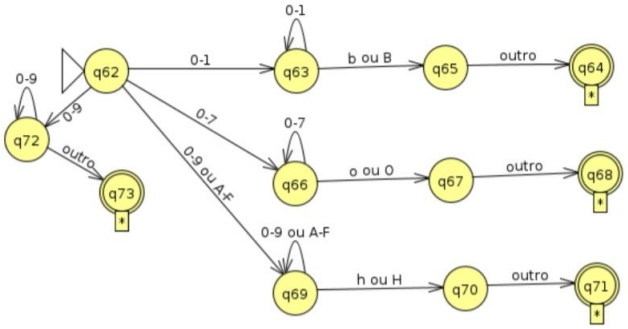


**STRINGCONSTANT**

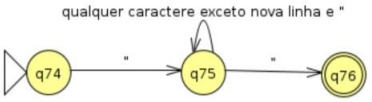


**FLOATCONSTANT**

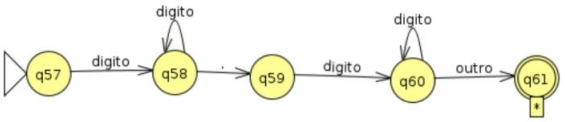


Para ver o documento completo com todos os diagramas, confira o anexo “Diagramas de Transição” no diretório principal do repositório do GitHub.

# 4. Descrição da tabela de símbolos

## a. Implementação

A tabela de símbolos foi implementada usando uma estrutura *dict* do python, onde a chave dos valores é o nome do identificador passado no código.

## b. Símbolos armazenados

A tabela de símbolos armazena todos os identificadores do programa, ou seja, nomes de variáveis de funções.

### c. Atributos escolhidos para armazenar

Os atributos escolhidos para se armazenar na tabela de símbolos foi o nome do identificdor, seu tipo, linha que foi declarada e linhas onde o identificador foi referenciado.

Identificadores que não tenham sido declarados (variáveis usadas sem declaração ou funções chamadas sem declaração), ficam com a flag 'NOT_DECLARED' no atributo 'declared_line' e 'NO TYPE' no atributo 'type'.

Ex: para um identificador "aux", de tipo *int*, delcarada na linha 7 e referenciada apenas na linha 8, sua entrada na tabela de símbolos seria:

{
'aux':{
'name':'aux', 'type': 'int', 'declared_line': 7,
referenced_lines':[8]
},
}

# 5. Descrição do PLY

PLY é uma implementação das ferramentas de parsing LEX (um gerador de analisador léxico) e YACC (Yet Another Compiler Compiler - ferramenta para análise sintática) feita totalmente em Python, por David M. Beazley.

Neste primeiro trabalho, utilizamos apenas o ply.lex, ferramenta de análise léxica. Para isso, primeiro precisamos definir o que serão nossos *tokens*.
Para isso, precisamos seguir o padrão: Criar uma variável "t_<nome do token>" que recebe uma expressão regular que reconhece a sequência de caracteres daquele token.
Por exemplo, para definir os tokens PLUS (símbolo de adição) e FLOATCONSTANT (constante numérica com parte decimal) fazemos:

```
t_PLUS = r'\+'                              # reconhece o caracter "+"
t_FLOATCONSTANT = r'\d+\ . \d+'
# reconhece numeros seguido de um ponto seguido de um outro número
```

Além disso, precisamos definir quais as palavras reservadas da nossa linguagem (pode ser feito da maneira acima, mas o ply.lex oferece um jeito mais fácil) criando um dict com a key sendo a palavra ("regex") e o valor sendo seu token. Por exemplo, para as palavras reservadas *int, float* e *string*, fariamos:

```
reserved = {'int':'INT', 'float':'FLOAT', 'string':'STRING'}
```

Ou seja, toda vez que o analisador "ler" a palavra "int", ele vai associá-la ao token "INT".

Definimos também o que será ignorado pelo nosso analisador. Quais entradas ele não vai reconhecer como token nenhum. Exemplo, ignoramos em nosso programa quaisquer espaços e tabulações, seguindo o padrão definido pelo ply.lex de criar uma variável *t_ignore* e atribuir à ela o regex (ou no nosso caso, a "string") que reconhece aquilo que deve ser ignorado:

```
t_ignore = '\t'
```

Feito tudo isso, criaremos nossa coleção de tokens. Criamos uma variável *tokens* que recebe uma lista com o nome de todos os tokens que foram definidos até agora, ou seja, tudo que vem depois de *t_* nas variáveis.

```
tokens = ['INT', 'FLOAT', 'STRING', 'PLUS', 'FLOATCONSTANT']
```

Depois, é só fazermos um

```
lexer = lex.lex()
```

que nosso analisador léxico está construído e associado à variável *lexer*. Agora, precisamos passar para ele a entrada que queremos analisar. Para isso, recebemos essa entrada de alguma forma (lendo um arquivo, pedindo para o usuário digitar no terminal, etc) e passamos para nosso lexer como

```
lexer.input(dados)
```

onde *dados* é a representação em string do que vamos analisar.

Agora, sempre que chamarmos

tok = lexer.token()

o lexer atribui à nossa variável *token* o próximo token do input que passamos à ele, de modo que podemos iterar sobre todos os tokens reconhecidos pelo nosso lexer e fazer as operações necessárias à ele.
Por exemplo, um resumo de como criamos nossa tabela de símbolos foi identificar se o token era do tipo 'IDENT', e caso fosse adicionamos ele à nossa tabela de símbolos (fazendo as checagens necessárias, mas que aqui foram omitidas)

```
tok = lexer.token()
if tok.type == 'IDENT':
      ## operações feitas para alocação do token na tabela de símbolos
```

Assim, podemos criar o output do nosso programa a cada token que é lido. Adicioná-lo a uma lista de todos os tokens reconhecidos, criar a tabela de símbolos, etc.

No nosso caso, nossa tabela de símbolos é retornada com as informações de nome, tipo, linha onde o identificador foi declarado e linhas onde foi referenciado. Exemplo, se nossa entrada tiver

```
10|  (...)
11|  int a = 1;
12|  int b = a + 1;
13|  (...)
```

Nossa tabela de símbolos terá as entradas

| NOME | TIPO | LINHA DECLARADA | LINHA REFERENCIADA |
|---|---|---|---|
| a | int | 11 | 12 |
| b | int | 12 | - |

Para exemplificar melhor uma entrada e uma saída, vamos pegar parte do programa exemplo (prog1.lcc) que entregamos com o trabalho:

```
def functionName(int a) {
  int b;
  int z;
  b = a + 2;
  z = b + 1;

  string message;
  message = "mensagem";
  print(message)
  print(z);
} |

// esse comentario será ignorado

/* esse
tambem */
```

O que esperamos de saída:

1. O aviso do erro léxico na última linha, no carácter “|”
2. A tabela de símbolos mostrando a declaração, tipo e referências das variáveis *a*, *b*, *z*, e *message* e da função *functionName*

Saída:

```
D:\Documents\Git\UFSC\Compiladores\AL1>py main.py programas/prog1.lcc

|        ERRO LÉXICO ENCONTRADO        |
|      -> Caracter:  '|'
|      -> Linha:      11
|      -> Coluna:     3

========= Symbols Table =========
+--------------+--------+----------+------------+
|     NAME     |  TYPE  | DECLARED | REFERENCED |
+--------------+--------+----------+------------+
| functionName |  def   |    1     |     []     |
|      a       |  int   |    1     |    [4]     |
|      b       |  int   |    2     |   [4, 5]   |
|      z       |  int   |    3     |  [5, 10]   |
|   message    | string |    7     |   [8, 9]   |
+--------------+--------+----------+------------+
```

# 6. Alterações

Abaixo, as alterações feitas na gramática:

- Foi adicionado valores TRUE e FALSE como terminais
- Foram adicionados tokens de comentário (ignorados na análise)

# Link para o repositório do Github:

https://github.com/felipecampossantos/AL1_INE5426

## Links Úteis

https://www.dabeaz.com/ply/
https://johnidm.gitbooks.io/compiladores-para-humanos/content/part1/lexical-analysis.html
https://www.dabeaz.com/ply/PLYTalk.pdf
https://sites.google.com/site/2012pcs25086482782/home/o-analisador-lexico
https://earthly.dev/blog/python-makefile/